

Case Studies

ШАД, Рекомендательные системы
2025/26, лекция 12

Даня Ткаченко

Руководитель службы ML-сервисов,
Яндекс Лавка

Яндекс



План занятия

На лекции:

1. Подход к дизайну рексистемы с нуля
2. Полный разбор на примере e-grocery (Лавка)
3. Ключевые различия с ним для
 - Онлайн-кинотеатра (Кинопоиск HD)
 - Медиа-фида (Дзен)

На семинаре:

- В еще больших деталях посмотрим на конкретные решения внутри Лавки

Дисклеймер

- Все решения осознанно упрощены для образовательных целей
- Лекция не является полным рассказом про устройство конкретных рантаймов и моделей
- Лекция не является гайдом к прохождению собеседований по ML System Design в рексис, хотя и сильно помогает с этим
- Все совпадения с реальными рантаймами случайны
- Автор вообще ни за что не несет ответственность, отстаньте от него

Зачем это все надо

- Мы послушали много разных лекций про разные составные куски рекомендательных систем
 - Устройство разных моделей ранжирования и кандидатогенерации
 - Подходы к борьбе с разными bias'ами
 - Изучили элементы построения рекомендательных рантаймов
- Сегодня попробуем получить blueprint и какую-то интуицию к тому, как строить решение относительно конкретной ситуации, с которой вы потенциально столкнетесь
- Заодно посмотрим несколько разных примеров

Подход к дизайну рексистемы с нуля

Часть 1



Что главное в рексистеме?



A complex system that works is invariably found to have evolved from a simple system that worked. A complex system designed from scratch never works and cannot be patched up to make it work.

– Gall's law

Отсюда общий blueprint

- Сначала строим простое, но работающее решение
- Критикуем наше простое решение
 - Выделяем точки роста с учетом тех особенностей системы, которые мы доосознали по ходу строения простого решения
 - Предлагаем ответы на эти точки роста
- Строим новое, более полное решение

Отсюда общий blueprint

- Сначала строим простое, но работающее решение
- Критикуем наше простое решение
 - Выделяем точки роста с учетом тех особенностей системы, которые мы доосознали по ходу строения простого решения
 - Предлагаем ответы на эти точки роста
- Строим новое, более полное решение

Моя личная инженерная максима:

- Временные решения – часть жизни любого инженера и рантайма
- Принимать их, однако, лучше всего, если вы понимаете, какое решение долгосрочно правильное
- Чтобы не сделать чего-то, что в корне противоречит этому долгосрочно правильному решению

Отсюда общий blueprint

- Сначала строим простое, но работающее решение
- Критикуем наше простое решение
 - Выделяем точки роста с учетом тех особенностей системы, которые мы доосознали по ходу строения простого решения
 - Предлагаем ответы на эти точки роста
- Строим новое, более полное решение

Моя личная инженерная максима:

- Временные решения – часть жизни любого инженера и рантайма
- Принимать их, однако, лучше всего, если вы понимаете, какое решение долгосрочно правильное
- Чтобы не сделать чего-то, что в корне противоречит этому долгосрочно правильному решению

Оговорка:

- Иногда даже просто осознать такое правильное решение может быть **крайне** дорогим действием
- В этом случае лучше просто довериться вашему опыту и интуиции
- Какое-то работающее решение в любом случае лучше, чем никакого

Пайплайн построения простого решения

- Определяемся с целеполаганием
- Определяем ключевые особенности и ограничения системы
- Набрасываем техническую архитектуру
- Набрасываем архитектуру ML-решения
- Фиксируем сетап экспериментирования

Важно:

- Это примерный порядок действий
- Иногда, если целеполагание непонятно с ходу, полезно начать со второго пункта
- Целеполагание при этом в любом случае нужно зафиксировать прежде, чем переходить к конкретным техническим шагам
- На практике для меня это часто является маркером взрослости инженера

Целеполагание

- Находим ключевую бизнес-метрику, которую хотим вырастить
- Связываем ее с оффлайн-метрикой, которую может растить модель
- Определяем ключевой таргет модели/моделей

Важно понимать:


- Это самый главный этап
- Если допустить грубую ошибку здесь, ее нельзя будет вытащить никакой сложной моделью ниже
- Многим часто хочется начать делать уже что-нибудь, и часто это полезное свойство
- При такой логике этот этап кажется самым логичным для быстрого пропуска
- Очень важно этого не делать
- Отчасти для того, чтобы это нивелировать, мы и строим именно простое решение в начале

Ключевые особенности и ограничения системы

- Размеры каталога и множества пользователей
 - Требования к доступности, фильтрации, прочие продуктовые ограничения
 - Отдельно: требования к скорости ответа
 - Устройство интента пользователя
 - Основные bias'ы, которым в большей степени подвержена система
-
- По сути этот этап призван подготовить материальную базу для дизайна последующих этапов
 - Здесь чистый брейншторм и сбор всех ограничений

Архитектура технического решения

- Используем те блоки, которые мы обсуждали в лекциях про устройство рантаймов и оффлайнов
- Но только те, которые нужны с учетом наших ограничений
- Здесь решаем, как принципиально будет выглядеть пайплайн ранжирования
- Как будет выглядеть фильтрация, шардирование, доставка новых данных
- В том числе, есть ли необходимость в рантаймизации хранилища пользователей и айтемов



Архитектура ML-решения

- Устройство кандидатогенерации
 - Список кандидатогенераторов
 - Устройство основных моделей кандидатогенерации
 - Способ балансировки кандидатогенераторов
- Модели ранжирования
 - Принципиальное устройство
 - Выбор самой модели
 - Устройство ручных фичей
 - Лосс

Полезный подход для быстрой генерации идей:

- Сформулируйте ключевых «актеров»
- Чаще всего это пользователь, айтем и контекст
- Сформулируйте несколько идей для кандидатогенерации/фичей для каждого актора
- Для каждой пары акторов

Сетап экспериментирования

- Устройство АБ-эксперимента
 - Какой сплит будем использовать
 - Какой критерий/мощность/уровень значимости
 - Какая нужна длина эксперимента
 - Какие могут быть интересны дополнительные срезы
- Ключевые метрики
 - Фиксируем список, опираясь на изначальное целеполагание
 - Делаем его более широким для удобства интерпретации
- Метрики-антагонисты
 - Фиксируем метрики, которые помогут понять, что происходит, когда что-то (неизбежно) пойдет не так

Важная проверка:

- Перед запуском эксперимента важно зафиксировать конкретную гипотезу, которую проверяете
- Иначе при большом количестве метрик вы всегда найдете что-то приятное, что у вас покрасится

Весь план в одном слайде


- Сначала строим **простое, но работающее** решение
 - Определяемся с целеполаганием
 - Находим ключевую бизнес-метрику, которую хотим вырастить
 - Связываем ее с оффлайн-метрикой, которую может растить модель
 - Определяем ключевой таргет модели
 - Определяем ключевые особенности и ограничения системы
 - Размеры каталога и множества пользователей
 - Требования к доступности, фильтрации, прочие продуктовые ограничения
 - Устройство интента пользователя
 - Основные bias'ы
 - Набрасываем техническую архитектуру
 - Используем те блоки, которые мы обсуждали в лекциях про устройство рантаймов и оффлайнов
 - Но только те, которые нужны с учетом наших ограничений
 - Набрасываем архитектуру ML-решения
 - Устройство ключевых моделей кандидатогенерации и ранжирования
 - Состав датасета
 - Модель, фичи и лосс
 - Фиксируем сетап экспериментирования
 - Устройство АБ-эксперимента
 - Ключевые метрики
 - Метрики-антагонисты
- Критикуем наше простое решение
 - Выделяем точки роста с учетом тех особенностей системы, которые мы доосознали по ходу строения простого решения
 - Предлагаем ответы на эти точки роста
- Строим новое, более полное решение

Пример 1: e-grocery (Лавка)

Часть 2



Ключевые особенности и ограничения



**Рекомендации
на главной**

Где вообще рекомендации?

На очень многих поверхностях

- Они активно каннибализируют друг друга
- Сложный пользовательский путь
- Мы тут немного за маркетолога в оффлайн-магазине, но немного менее наглого

Ключевые особенности и ограничения

Пользователь чаще всего достаточно хорошо нам известен:

- Большая доля регулярно покупающих пользователей
- Ничего нельзя сделать без залога – есть дополнительная информация о пользователе из экосистемы
- Холодный старт чуть менее актуален

У пользователя чаще всего уже есть интент что-то купить:

- Очень мало кто заходит в приложение Лавки просто поскроллить
- Нужно сильно не мешать, при этом продать еще что-то по дороге
- Если мешать сильно, уйдет, это все же не оффлайн-магазин

Ключевые особенности и ограничения

- Небольшой каталог на каждом дарксторе (чаще всего до 3000 айтемов)
 - хорошо структурирован, данные надежны
- Пользователей – десятки миллионов, SLA на ответ с учетом спекулятивных загрузок до 300мс на клиенте
- Порядок числа RPS -- сотни
- Продукты становятся доступными или недоступными мгновенно
 - Когда они заканчиваются или привозятся новые
- Продукты могут портиться, поэтому важно, чтобы новые товары появились в выдаче быстро, если рекомендации -- большой кусок пользовательского пути

- **0–100 мс** – отклик ощущается как мгновенный.
- **100–300 мс** – небольшая, но заметная задержка.
- **300–1000 мс** – пользователь чувствует, что система "думает".
- **>1 сек** – внимание пользователя начинает рассеиваться.
- **>3 сек** – **53% пользователей покидают сайт** (по данным Google).

Целеполагание

Обсудим простой изначальный подход:

- Предположим, что ключевая задача бизнеса – рост GMV (Gross Merchandise Value), общей суммы денег с продаж
- В оффлайне мы можем спроксировать это через NDCG, где gain определяется, как цена товара
- Отсюда очевидный таргет для моделей – покупка

В рамках дальнейший рассуждений остановимся на задаче построения рекомендаций на экране корзины

Целеполагание


Обсудим простой изначальный подход:

- Предположим, что ключевая задача бизнеса – рост GMV (Gross Merchandise Value), общей суммы денег с продаж
- В оффлайне мы можем спроксировать это через NDCG, где gain определяется, как цена товара
- Отсюда очевидный таргет для моделей – покупка

Проблемы такого целеполагания:

- Деньги в моменте – это хорошо, но это может не полностью соответствовать деньгам в долгосроке
- Бизнес все же скорее всего хочет растить сумму LTV по пользователям
- Метрика не учитывает, что пользователи могут покупать сразу несколько одинаковых товаров
- Все это никак не учитывает каннибализации поверхностей

Техническая архитектура



- При таком размере каталога и RPS никакого смысла в шардировании нет
 - Пользователи редко покупают что-то чаще раза в сутки, скорее всего достаточно статического хранилища пользовательских профилей с обновлением раз в сутки
 - Новые товары хоть и подразумевают маленькие задержки, но выход нового товара известен сильно заранее, все это позволяет обойтись статическим шардом, который строится раз в сутки
 - Фильтрация важна критически, прямо на сервисе рекомендаций держим кеш текущих доступных товаров, на обогащающем бэке дофильтровываем
 - Дополнительно фильтруем по текущей корзине (т.к. не хотим показывать то, что пользователь уже добавил)
 - И по легальным ограничениям: скорее всего это табак, алкоголь, возможно, что-то 18+ типа презервативов
- Видим, что нам в целом подходит суперванильная схема устройства рекоммендера

Техническая архитектура: проблемы

- Пользователь может довольно долго собирать корзину, в таком случае его действия внутри сессии начинают обретать бОльшую важность
 - Особенно важно для пользователей, про которых мы пока что знаем меньше
 - Скорее всего нужно что-то feature-store-подобное для пользовательской части
-
- Если мы строим какие-то общие решения для решения проблемы каннибализации, вроде аплифтов покупки на этой поверхности относительно покупки вообще, нам точно понадобится полный feature-store
-
- Если каталог все же начнет расти, нам может понадобится вынос кандидатогенерации/фичей в отдельный сервис для оптимизации

Яндекс

Рантайм-трансформер в рекомендациях Яндекс Лавки



Марк Нарусов

ML-инженер,
Яндекс Лавка



можете, кстати, глянуть, как это у нас сделано

ML-архитектура: кандидатогенерация

- Реально обойтись совсем без нее, т.к. у нас порядка 3000 товаров на дарксторе
- Если в простой версии все же нужна, простые бейзлайны скорее всего уже сработают хорошо:
 - Товары из истории покупок
 - Похожие на них товары
 - Товары, сопкупаемые к текущей корзине
 - Новые и популярные товары

ML-архитектура: ранжирование

- В простом варианте можем сделать одностадийное ранжирование
 - Очень вероятно, что это станет ограничением, и понадобится вторая стадия при текущем количестве кандидатов и SLA на ответ (сильно впритык)
- Модель: бустинг / dcn-v2 / что-то другое полносвязное, т.к. решаем задачу ранжирования и можем себе позволить
- Таргет: уже обсудили раньше
- Сетап ранжирования:
 - Хотим ранжировать по матожиданию выручки
 $\Rightarrow p(\text{buy} \mid \text{show}) * \text{цену}$
 - либо вшиваем цену в ранжирующий лосс
 - e.g., в качестве лосса берем BCE или какой-то условный ранжирующий вариант BPR'a
- Датасет
 - Из прошлого пункта явно следует, что покупка против показа в слейте

ML-архитектура: ранжирование, фичи

3 актора: пользователь, товар, контекст (время, поверхность, корзина)

- Пользователь
 - Насколько часто покупает (с ограничением по времени, чтобы фичи меньше ехали)
 - Средний чек пользователя
 - Эмбеды 3 любимых категорий
- Товар
 - Число продаж товара/его категории/его производителя за последние X дней
 - Аналогично показы/CTR/CVR/wCTR/wCVR
 - Эмбединг
- Контекст
 - День недели
 - Число секунд с начала суток
 - Эмбед поверхности
 - Эмбед корзины
- Пользователь x Товар
 - Скор пользовательского и товарных эмбедов
 - Про устройство двухбашенки для лавки – на семинаре
 - Сколько раз пользователь покупал этот товар/его категорию/его производителя за X дней
- Пользователь x Контекст
 - Сколько пользователь обычно покупает в этот день/час
 - Скор эмбеда пользователя и эмбеда корзины (насколько характерна текущая корзина для него)
- Товар x Контекст
 - Насколько часто этот товар берут в это время, его CTR/CVR в это время
 - Близость товара к корзине

Ранжирование: проблемы

- Из-за сложного продуктового кейса с каннибализацией есть большое желание двинуться в сторону генеративной постановки, чтобы скинуть с себя различные проблемы с таргетом. Это полностью меняет архитектуру
- Бизнес на самом деле может хотеть не только GMV, а какую-то функцию от GMV и чистой прибыли, но в таком случае нужно предиктить маржу, т.к. она заранее неизвестна
- Не учли количество покупаемых айтемов в функции все так же

ML-архитектура: переранжирование

- Гигиенический минимум переранжирования:
 - Softmax (Boltzman) Sampling для борьбы с фидбек лутом
- Категориальное разнообразие из-за классической постановки
 - В перспективе можно усложнять до DPP или чего-то другого
- Скорее всего важна отдельная работа с новинками, можно пробовать через бандитные подмеси

готовим пост на хабре про нашу имплементацию, stay tuned

Сетап эксперимента:

- Классический пользовательский сплит
- Ключевая метрика – интегральный GMV
- Вспомогательные метрики:
 - Интегральная чистая прибыль (маржа)
 - Конверсия рекомендательной поверхности в покупку
- Метрики антагонисты:
 - GMV по категориям
 - Конверсия по позициям внутри поверхности
- Можно придумать что-то еще

Пример 2: онлайн-кинотеатр (Кинопоиск HD)

Часть 3



О чем поговорим

- В этом примере и дальше не будем делать полной остановки на всех местах, иначе сильно уйдем в самоповторы
- Поговорим про какие-то отдельные интересные места, которые значительно отличаются от нашего якорного кейса (Лавки)
- В случае кинопоиска – это
 - Разные технические и продуктовые места
 - Целеполагание
 - Карусельный интерфейс

Базовые технические и продуктовые отличия



- Каталог примерно 300-500к айтемов
 - Уже точно нужна кандидатогенерация, но это все еще в целом вполне себе бесшардовая схема
- Все потребление по факту строится от одного айтема:
 - Если пользователь смотрит серию сериала, он скорее всего дальше смотрит этот сериал
 - Если пользователь смотрит фильм, он скорее всего ничего не станет смотреть после
 - Так что рантайм-профиль пользователя может быть и не нужен (по аналогичной логике с лавкой он может быть нужен на более поздних этапах)

Базовые технические и продуктовые отличия

- Много холодных пользователей из-за раздачи подписок плюса, нужен нормальный онбординг
 - Netflix-trick для онбординга:
 - Показывают топ популярных фильмов
 - Юзер кликает — забираем фильм и удаляем все события пользователей, которые его высоко оценили
 - Перестраиваем топ и повторяем
- Много региональных ограничений, много разных видов подписок
 - Обязательно учитываем на раннем этапе в фильтрации
- Детский контент может замусоривать историю просмотров
 - На практике чаще всего просто удаляют

Целеполагание


- Что нужно бизнесу: подписки
- Само по себе количество подписок — не сильно хорошая метрика для АБТ
 - В коротком эксперименте в принципе не красится, т.к. событие очень редкое
- Как сделать из него что-то приличное
 - Строим прокси-метрику к подпискам, которая чувствительна в коротком АБТ и при этом с ними коррелирует
- Если можем положить напрямую в таргет, кладем, если нет, — кладем что-то похожее
- У нас скорее всего получится какая-то функция от
 - Total View Time / Log View Time
 - дискаверийного TVT / LVT
 - с отдельным сериальным фокусом, так как у них лучше ретеншн ⇒ подписки
 - с разными маркерами про досматриваемость и оценки

Целеполагание

Как обычно строят такие метрики:

- Выделяем какой-то список потенциально хороших метрик, которые могут влиять на долгосрочный эффект
 - Здесь часто что-то с очевидным ретеншн-эффектом типа просмотра сериалов
 - Также часто дискавери и разнообразие потребляемого контента
 - Ну и просто насколько часто пользователь пользуется и его основные метрики
- Выделяем метрики-кандидаты
 - Строим из базовых метрик каких-то 10 франкенштейнов
 - Ретроспективно, используя PSM-analysis или просто считая какие-то debiased-корреляции, понимаем, какие франкенштейны лучше показывают долгосрочный эффект
 - Тут можно и простую модель пофитить, но нужна интерпретируемость
- Проверяем на golden-set'е экспериментов

Карусельный интерфейс



Общая персональная выдача

- Продолжить просмотр
- Похожие на...
- Жанровые блоки
- Огромные постеры

2 похода:

- Выбрать блоки, потом ранжировать внутри и между собой
- Генерировать общий пул, потом нарезать продуктово или еще как-то

На практике делают оба сразу. Внешнее ранжирование часто бандитное из-за гетерогенности блоков

Пример 3: медиа-фид (Дзен)

Часть 4



О чем поговорим

Что отличает от предыдущих примеров:

- Масштаб через UGC и интент
- Баланс объяснимости и релевантности
- Появляется второй вид пользователя -- автор
- Мультиmodalность контента

Масштаб

- Индекс – сотни миллионов айтемов
 - Абсолютно точно нужно шардирование
- Явного интента просто нет, пользователи заходят посмотреть «что-нибудь»
- Отсюда потребление дешевое и короткое, точно нужны нормальные абстракции для рантаймового feature-store'a
- Сама архитектура feature-store'a очень сложная, с отдельным приседанием под холодные айтемы
- Не все айтемы надежны, т.к. мы работаем с UGC, нужен развесистый пайплайн-модерации и мгновенных банов
- Сложные рантайм-фильтрации
- Явная потребность в выносе сервисов кандидатогенерации и фичей из-за масштаба

Счастье авторов

В системе присутствует вторая сущность — автор, со своими интересами и ожиданиями. Авторы **рассчитывают** на получение показов в рекомендациях. Их отсутствие вызывает жалобы и эскалации.

Типичные подходы:

- Встроенный в модель item exploration (на бандитах или что-то в таком духе)
- PID-контроллеры для стабилизации объема показов
- Явные квоты на показы в системе




не забывайте, где настоящее счастье

Мультимодальность

Типы контента:

- статьи
- видео
- тиктоки

Всё замешано в одном фиде




Интерфейс влияет на таргет

На больших интерфейсах (лента, подборки) можно оптимизировать на длинные сессии

На маленьких (один видос на экране или даже карусель) — скорее нет:

- длинные статьи/видео будут скипаться
- получаем артефакты (длинные видео)

Рекомендуем посмотреть



Деградация моделей и свежесть

В Дзене быстро появляются и исчезают тренды

- Модели деградируют быстрее, чем в Лавке или Кинопоиске
- Помогает:
 - online дообучение
 - конвейеры

Антифрод и метрики

Авторам платят за показы → начинается фрод

- Крутят ботов, накручивают CTR
- В хорошей системе таргет антифрод-aware, как и целевая метрика
- Команды работают очень тесно



Что мы узнали сегодня

- Посмотрели на blueprint для дизайна рексистемы
- Опробовали его на Лавке
- Посмотрели еще несколько других систем, чуть-чуть покопались в том, какая между ними разница
- Хорошо провели время



tg: @deadpadre

Спасибо!

Даня Ткаченко,

Руководитель службы ML-сервисов Яндекс Лавки

Белград 2026

