

Рекомендательная система на примере Яндекс Лавки

ШАД, Рекомендательные системы
2025/26

Руслан Кулиев

ML-разработчик
Яндекс Лавка, группа рекомендательных и поисковых сервисов






План занятия

1. Особенности домена
2. Прекрасное настоящее
3. Светлое будущее

Особенности домена

Часть 2

Яндекс Лавка



Доменная специфика

Доменная специфика

С точки зрения пользовательского поведения

- Сильный интент на покупку
- Повторяемость и регулярность покупок
- Небольшой, стабильный каталог
- Добавление в корзину – ключевой сигнал
- Множество поверхностей
- Слейты – 2d-поверхности

Интен

Интент

- Юзер хочет продуктов
 - С быстрой доставкой

Интент

- Юзер хочет продуктов
 - С быстрой доставкой

Интент

- Юзер хочет продуктов
 - С быстрой доставкой
- Мы не должны удовлетворить интент
 - Не считая поиск

Интент

- Юзер хочет продуктов
 - С быстрой доставкой
- Мы не должны удовлетворить интент
 - Не считая поиск
- Мы должны растить позитивный опыт
 - Дополнить интент
 - Что-то комплементарное, что-то из разряда спонтанных покупок, что-то серендипное
- Корзина – важнейший сигнал
- Де факто мы балансируем между бюджетом, долгосрочными интересами пользователя и краткосрочным интентом

Повторяемость покупок и небольшой каталог

Повторяемость покупок и небольшой каталог

- Personal Top-K – очень сильный бейзлайн
- Предпочтения в среднем довольно устойчивы
- Причем есть явные category, которые, как кластера интересов, еще более устойчивы

Как мы можем это использовать

- У юзера сильный интент что-то купить
 - Корзина – ключевой сигнал
 - Таргет – `cart_update`
 - Близость (комплесментарность) корзине – один из ключевых сигналов
- Повторяемость покупок
 - Фичи к истории хороши
 - Трансформеры по длинной истории хороши
- Целевое действие – покупка, и целевая метрика – денежная
 - Перевзвешиваем таргет на цену/маржу
- Геометрия слейтов
 - Pointwise работает хуже
- Небольшой устойчивый каталог
 - Обучаемые эмбеда хороши
 - Можем считать полный софтмакс

Прекрасное настоящее

Часть 2

Как живет наш сервис сейчас

Как живет наш сервис сейчас

- Одностадийное ранжирование
 - Небольшой каталог
 - Ультрасовременные оптимизации плюсового сервиса

Как живет наш сервис сейчас

- Одностадийное ранжирование
 - Небольшой каталог
 - Ультрасовременные оптимизации плюсового сервиса
- Небольшие пагинационные пачки
 - Позволяют эффективно адаптироваться к изменениям корзины и реактивно реагировать на сигналы

Как живет наш сервис сейчас

- Одностадийное ранжирование
 - Небольшой каталог
 - Ультрасовременные оптимизации плюсового сервиса
- Небольшие пагинационные пачки
 - Позволяют эффективно адаптироваться к изменениям корзины и реактивно реагировать на сигналы
- Две ключевые ранжирующие программы на 6 основных поверхностях
 - Strongly упрощает жизнь разработчиков
 - Концептуально похожие, что обеспечивает переиспользование тех же таргетов

Как мы ранжируем

Как мы ранжируем

- Собираем пул по слайтам – пагинационным пачкам
 - Собираем k негативов вокруг позитива строго в границы пагинационной пачки
 - Только с целевых поверхностей

Как мы ранжируем

- Собираем пул по слайтам – пагинационным пачкам
 - Собираем k негативов вокруг позитива строго в границы пагинационной пачки
 - Только с целевых поверхностей
- Таргет – карт апдейт с перевзвешиванием на денежный признак

Как мы ранжируем

- Собираем пул по слайтам – пагинационным пачкам
 - Собираем k негативов вокруг позитива строго в границы пагинационной пачки
 - Только с целевых поверхностей
- Таргет – карт апдейт с перевзвешиванием на денежный признак
- Сэмплы перевзвешаны согласно доле целевого события

Как мы ранжируем

- Собираем пул по слайтам – пагинационным пачкам
 - Собираем k негативов вокруг позитива строго в границы пагинационной пачки
 - Только с целевых поверхностей
- Таргет – карт апдейт с перевзвешиванием на денежный признак
- Сэмплы перевзвешаны согласно доле целевого события
- Ранжирующий катбуст на `yetirank`

Как мы ранжируем

- Собираем пул по слайдам – пагинационным пачкам
 - Собираем k негативов вокруг позитива строго в границы пагинационной пачки
 - Только с целевых поверхностей
- Таргет – карт апдейт с перевзвешиванием на денежный признак
- Сэмплы перевзвешаны согласно доле целевого события
- Ранжирующий катбуст на yetirank
- Обучаемся на коротком временном горизонте – порядка 2-3 недель на обучение, по паре дней на валидацию-тест

Как мы ранжируем

- Собираем пул по следам – пагинационным пачкам
 - Собираем k негативов вокруг позитива строго в границы пагинационной пачки
 - Только с целевых поверхностей
- Таргет – карт апдейт с перевзвешиванием на денежный признак
- Сэмплы перевзвешаны согласно доле целевого события
- Ранжирующий катбуст на yetirank
- Обучаемся на коротком временном горизонте – порядка 2-3 недель на обучение, по паре дней на валидацию-тест
- Обучаемся строго на залогированных фичах
 - Единственное исключение – внедрение новой нейросетевой модели, там мы часто аккуратно подклеиваем эмбеда, выдерживая временной лаг поставки данных и доезда фичи до прода

Что еще

- Томпсоновское сэмплирование в проде
 - Обеспечивает нам разнообразие выдачи и прогрев холодных товаров

Что еще

- Томпсоновское сэмплирование в проде
 - Обеспечивает нам разнообразие выдачи и прогрев холодных товаров
- Переранжирование для разнообразия выдачи
 - Сначала собираем top-300 кандидатов, поверх делаем dpp по контентным эмбедам

Cutting edge

- Двухбашенные модели в проде
 - В т.ч. в рантайм
- Добавляем больше контента и inductive bias
- Target aware на подходе

Самые жгущие сигналы

- Трансформеры
- Счетчики к истории
 - И долгосрочные, и краткосрочные
- Близость к корзине

Светлое будущее

Часть 3

Ключевые вызовы

- Базовое качество
 - В т.ч. в ассистенте
 - В т.ч. в рантайм-сценариях
- Лучшая метрика для оптимизации
- Каннибализация и разрозненные модели
- Персонализация приложения
- Инфровые стройки
 - Расширение каталога
 - Рантайм
 - Актуализация моделей

Базовое качество

- Улучшать фичи для ранжирующей модели
 - Делать трансформеры и прочие модели быстрее, выше и сильнее – как в оффлайне, так и в рантайме
 - Argus
 - OneRec
 - GenSar
 - ...
- Улучшать ранжирующую модель
 - DCN-v2
 - RankMixer
 - Onetrans
 - ...
- Интегрировать языковые модели
 - PLUM, GenSar

Что оптимизировать

- Деньги – всегда хорошо для бизнеса, но вряд ли оптимально
- Развивать дискавери-сценарии и сложные апlifты
- В идеале заполучить и оптимизировать долгосрочные метрики
 - Прокси-метрики к Retention, LTV, smth else
 - RL

Каннибализация

- Поверхности конкурируют друг с другом за товары
- Улучшение одной поверхности – всегда ухудшение другой
 - С точки зрения бизнес-импакта и перераспределения денег внутри приложения
- Хотим оптимизировать пользовательскую траекторию внутри приложения
 - Без ухудшения качества рекомендаций
- В т.ч. было бы славно иметь единую модель, которая знала бы про все действия на всех поверхностях
- И в т.ч. единую модель с поиском

Персонализация приложения

- Наша своего рода мечта и один из самых неопределенных проектов
- Подстраивать не просто товарную выдачу или категории в каталоге, но *само приложение* под особенности пользователей

Инфраструктура и котики

- Большая сила – большая ответственность
 - Большая Лавка – это уже достаточно большой каталог, чтобы ранжировать в одну стадию было тяжеловато
 - К тому же добавляются новые сценарии
 - Возвращение к кандидатогенерации, или переход к отдельным сервисам кандидатогенерации/фичеэкстракции, кажется неизбежным
- Простор для улучшения рантайма
 - Есть амбиции развивать рантайм-трансформеры, но текущая схема инференса и даже обработки пользовательских последовательностей к большим и тяжелым моделям не готова
- Конвейер моделей
 - Все еще точка роста, которая поможет лучше адаптироваться к сменам предпочтений

tg: @kuliev_re

Спасибо!

Руслан Кулиев

*ML-разработчик
Группа рекомендательных и поисковых сервисов
Яндекс Лавка*

Санкт-Петербург 2026